
Ариадна

Карта знаний R&D горно-металлургической отрасли


Хакатон Норникеля — задача «Научный клубок»

Команда «Ариадна» · 4 июля 2026

Проблема

- 1 453 документа, 4,9 ГБ — статьи, обзоры, отчёты, доклады на русском и английском языках
- Знания рассеяны по корпусу: опыт, числовые параметры, противоречия ищутся вручную — ни один эксперт не может перечитать всё
- Непонятно, где реально нет исследований: «пробелы» не видны, пока на них случайно не наткнёшься
- Вопросы звучат естественно («какие методы обессоливания подходят, если ...») — а корпус не структурирован для такого поиска

Решение одним взглядом



Каждый факт в графе — с провенансом до чанка-источника

Архитектура: двойной граф

- Лексический граф: Document → Chunk + векторный индекс (Qwen3-Embedding) — страховочный RAG
- Сущностный граф: онтология задания — 8 типов сущностей, 6 типов связей, два хаба — Experiment и TechSolution/Process
- Гибридный retrieval: граф + вектор, единое ранжирование чанков
- Роутер запросов без LLM: намерение определяют правила → шаблонные Cypher-запросы (свободный text2cypher запрещён)

Масштаб в цифрах

177

документов ядра

9 580

чанков

23,6 тыс.

сущностей

25 063

связей графа

8 179

числовых ограничений

175 / 177

документов с гео-
разметкой

620

автотестов (+3 xfail)

Точность чисел — не дело случая

- Концентрации, температуры, расходы и другие числовые параметры извлекает ТОЛЬКО регекс-нормализатор — никогда LLM
- LLM определяет, где искать; финальное число и единицу измерения проверяет детерминированное правило
- Ошибка в «сульфаты ≤ 300 мг/л» — не опечатка, а неверный технологический вывод для инженера
- 8 179 числовых ограничений в графе — каждое привязано к чанку-источнику

4 запроса жюри — отвечают все

- Q1. Обессоливание воды (сульфаты/хлориды/Ca/Mg/Na 200–300 мг/л, сухой остаток ≤ 1000 мг/дм³) — применимые методы с граничными концентрациями
- Q2. Циркуляция католита при электроэкстракции никеля — решения мировой практики и оптимальная скорость потока
- Q3. Распределение Au, Ag и МПГ между штейном и шлаком за 5 лет — эксперименты и публикации по теме
- Q4. Закачка шахтных вод в глубокие горизонты — честный пробел в корпусе + смежные альтернативы

Каждый ответ — с цитатами до конкретного чанка-источника

Карта пробелов

- Гар-матрица «материал x процесс»: показывает сочетания, для которых в корпусе нет экспериментов
- Q4 (закачка шахтных вод) — теме физически нечего ответить; система честно говорит «в корпусе не найдено» и предлагает смежные альтернативы
- Гео-разметка вскрывает перекося практики: только в РФ (only_ru) — 44 темы, только за рубежом (only_foreign) — 225 тем
- Пробел — не баг, а сигнал: куда направить R&D или литобзор

Верификация и работа эксперта

- Каждый факт несёт provenance: source, updated_at, confidence
- Противоречия (contradicts) подсвечиваются в подграфе ответа, а не прячутся
- Эксперт правит граф напрямую в Neo4j Browser — без переизвлечения корпуса
- Версионирование-минимум готово к аудиту решений

Стек — полностью локальный

- Neo4j — граф знаний + векторный индекс
- Qwen3.5-35B-A3B через Ollama (int4) — извлечение и синтез ответов, локально на DGX Spark
- Qwen3-Embedding-0.6B — эмбединги RU/EN
- Ни документ, ни вопрос, ни ответ не покидают контур — внешних API нет

Что дальше

- Рекомендации: похожие кейсы, эксперты по теме, смежные направления
- Литобзор с автоматическим консенсусом/разногласиями источников
- JSON-LD фасад для интеграции с внешними системами
- Масштабирование извлечения на весь корпус (1 453 документа)

Демо

- Streamlit-чат: вопрос → ответ с цитатами → подграф → карта пробелов
- Видео и материалы: disk.yandex.ru/d/Vo0tJWsdzO_slg
- Код: github.com/Dikoper/ARIADNA-NEO4j-RAG

Спасибо!